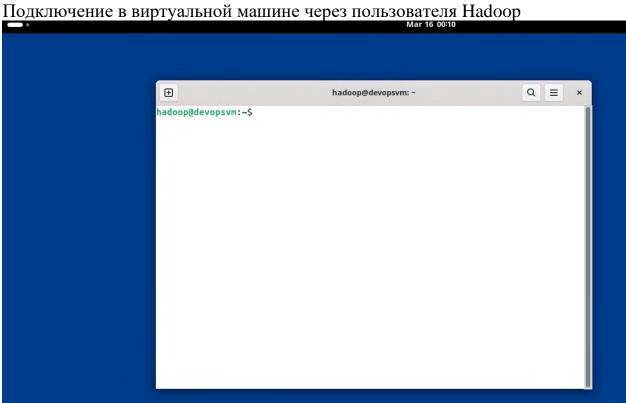
Введение

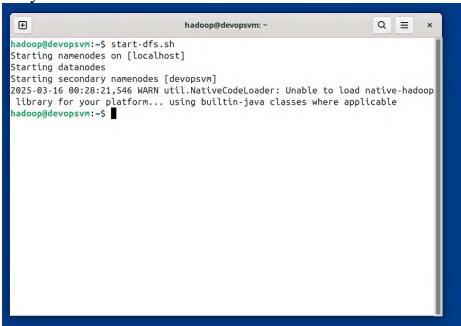
Цель: изучить основные операции и функциональные возможности системы, что позволит понять принципы работы с данными и распределенными вычислениями.

Основная часть

Шаг 1. Запуск Hadoop



Запуск HDFS



start-dfs.sh

Запуск YARN

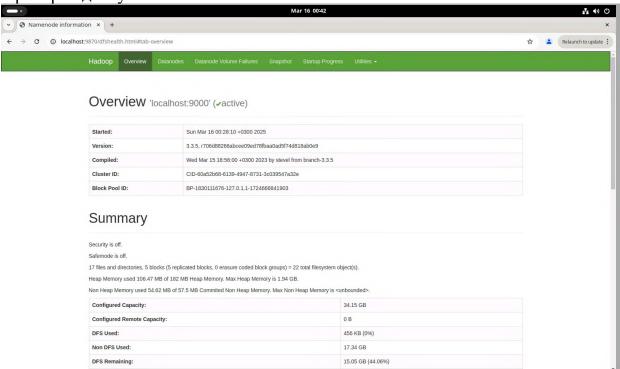
```
hadoop@devopsvm:~$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [devopsvm]
2025-03-16 00:28:21,546 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable hadoop@devopsvm:~$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
hadoop@devopsvm:~$
```

start-yarn.sh

Шаг 2. Проверка запущенных служб

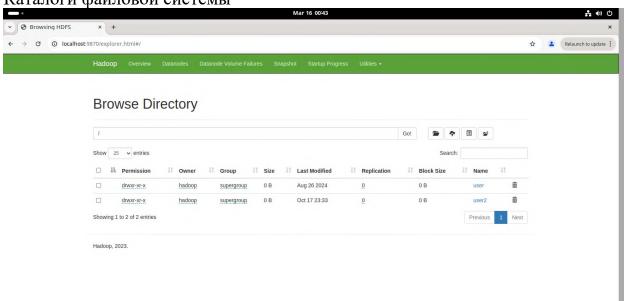
ips + hadoop@devopsvm: ~ Q = hadoop@devopsvm:~\$ start-dfs.sh Starting namenodes on [localhost] Starting datanodes Starting secondary namenodes [devopsvm] 2025-03-16 00:28:21,546 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable hadoop@devopsvm:~\$ start-yarn.sh Starting resourcemanager Starting nodemanagers hadoop@devopsvm:~\$ jps 20368 NodeManager 19746 DataNode 20230 ResourceManager 19527 NameNode 20808 Jps 19977 SecondaryNameNode hadoop@devopsvm:~\$

Проверка доступности системы



localhost:9870

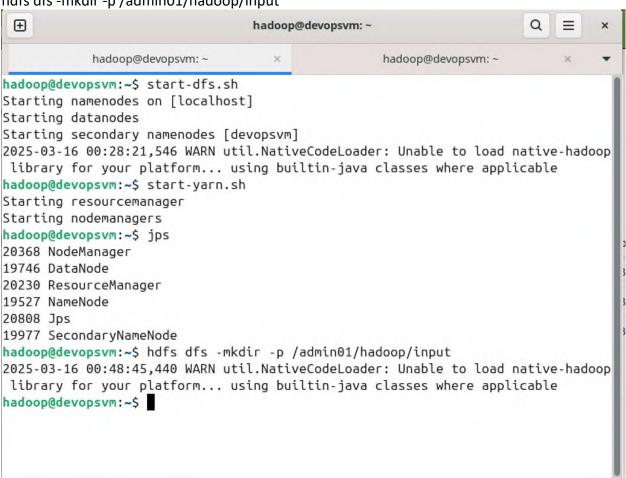
Каталоги файловой системы



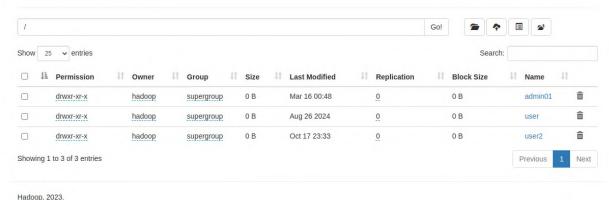
Проверка YARN Browsing HDFS × 3 All Applications C ① localhost:8088/cluste **All Applications** - Cluster Apps Running Cluster Nodes Metrics Active Nodes Decommissioning Nodes Scheduler Metrics Scheduler Type Scheduling Resource Type Capacity Scheduler [memory-mb (unit=Mi), vcores] <memory:1024, vCores:1> <memory:8192, vCores:4> Show 20 ➤ entries Scheduler Application Queue LaunchTime FinishTime ID -User No data available in table Showing 0 to 0 of 0 entries

Шаг 3. Подготовка рабочего пространства Создание директории в HDFS

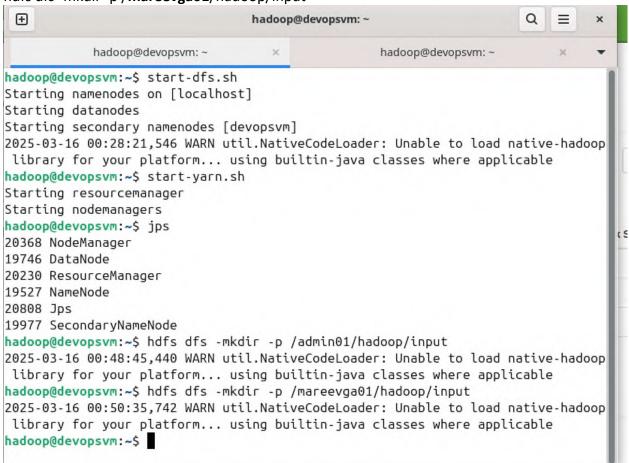
hdfs dfs -mkdir -p /admin01/hadoop/input



Browse Directory



hdfs dfs -mkdir -p /mareevga01/hadoop/input



Browse Directory



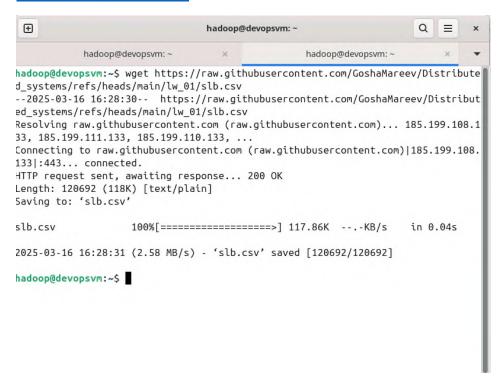
Шаг 4. Загрузка и подготовка данных

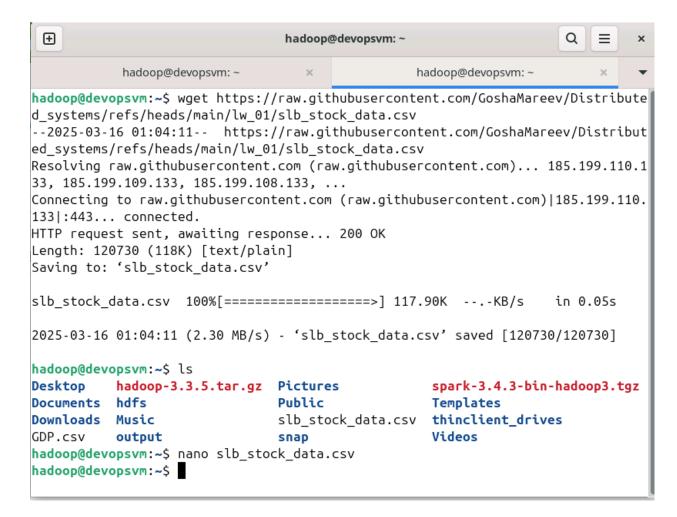
Скачивание файла с данными

*файл с данными был немного преобразован: сделан заголовок и изменено имя файла для простоты (все изменения отражены в репозитории) https://github.com/GoshaMareev/Distributed_systems/tree/main/lw_01

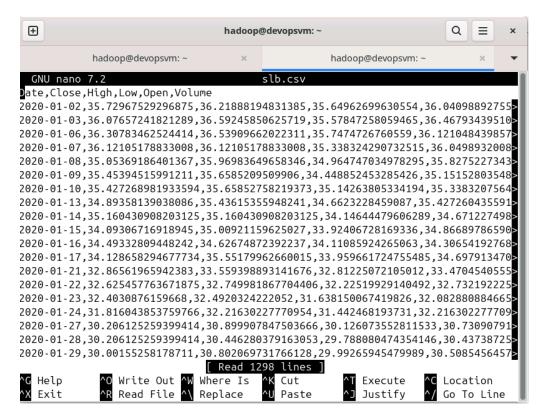
wget

https://raw.githubusercontent.com/GoshaMareev/Distributed systems/refs/heads/main/lw 01/slb.csv



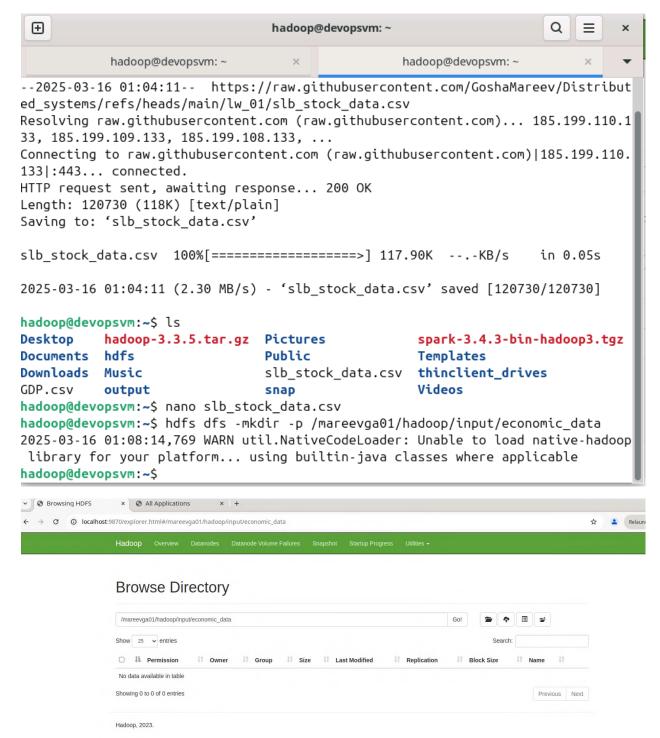


Nano slb.csv



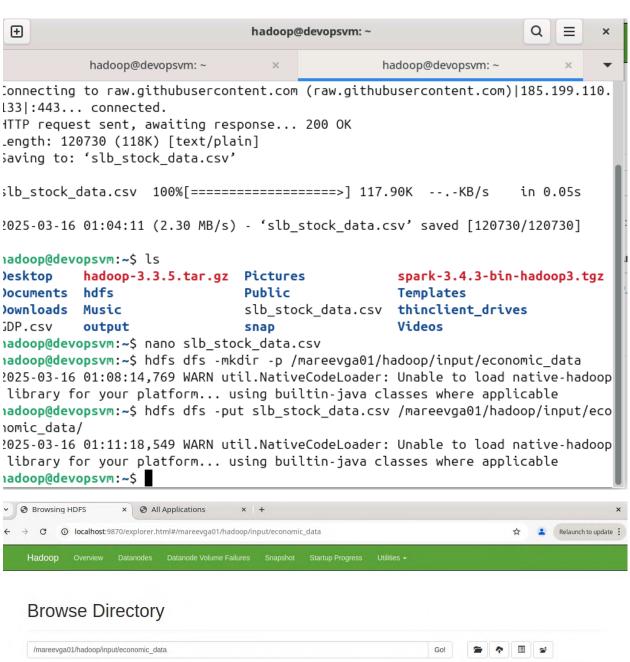
Создание директории для экономических данных

hdfs dfs -mkdir -p /mareevga01/hadoop/input/economic_data



Загрузка данных в HDFS

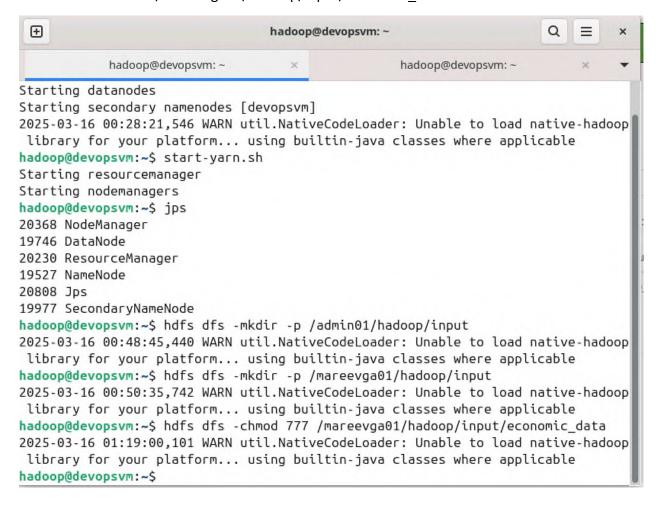
hdfs dfs -put slb.csv /mareevga01/hadoop/input/economic data/





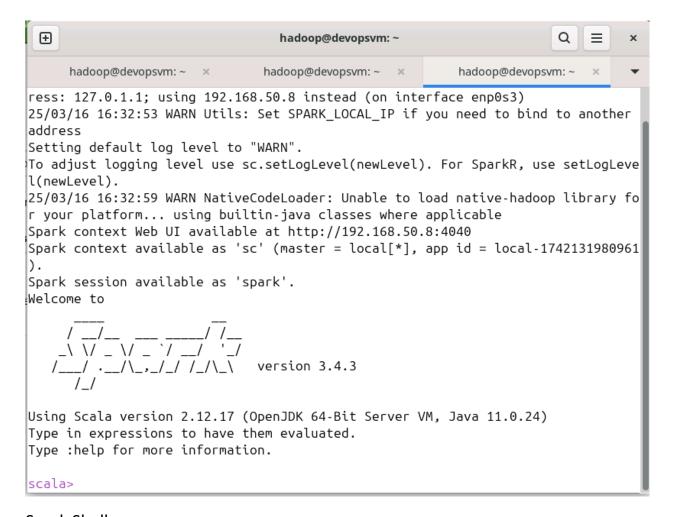
Установка прав доступа

hdfs dfs -chmod 777 /mareevga01/hadoop/input/economic data



Шаг 5. Обработка данных с помощью Spark

Spark-shell



Spark Shell:

Загрузка данных из HDFS с правильным URI

val data = spark.read.option("header", "true").csv("file:///home/hadoop/slb.csv")

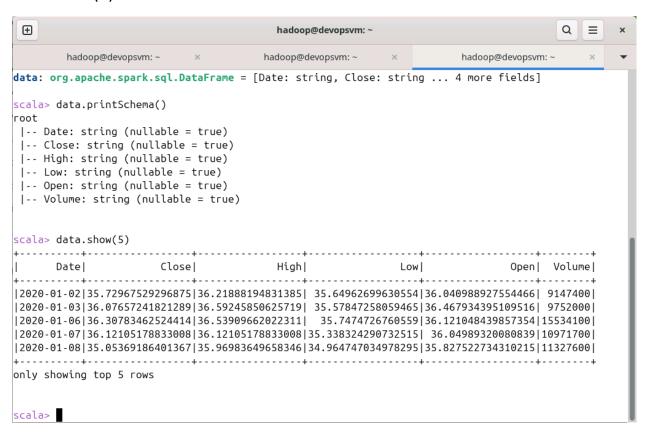
Проверка схемы данных

data.printSchema()

```
(+)
                                                                                               \equiv
                                           hadoop@devopsym: ~
        hadoop@devopsvm: ~ ×
                                         hadoop@devopsvm: ~ ×
                                                                          hadoop@devopsvm: ~
Spark session available as 'spark'.
Welcome to
                              version 3.4.3
Using Scala version 2.12.17 (OpenJDK 64-Bit Server VM, Java 11.0.24)
Type in expressions to have them evaluated.
Type :help for more information.
scala> val data = spark.read.option("header", "true").csv("file:///home/hadoop/slb.csv")
data: org.apache.spark.sql.DataFrame = [Date: string, Close: string ... 4 more fields]
scala> data.printSchema()
 |-- Date: string (nullable = true)
|-- Close: string (nullable = true)
 |-- High: string (nullable = true)
|-- Low: string (nullable = true)
|-- Open: string (nullable = true)
|-- Volume: string (nullable = true)
scala>
```

Первые 5 строк

Data.show(5)



Bce столбцы имеют строковый (string) формат, для вычислений нужно будет преобразовать:

Data – в формат даты

Close, High, Low, Open, Volume в числовой формат

Вычисление среднего значения

Фильтрация данных за последние 3 года

Расчет медианной цены закрытия

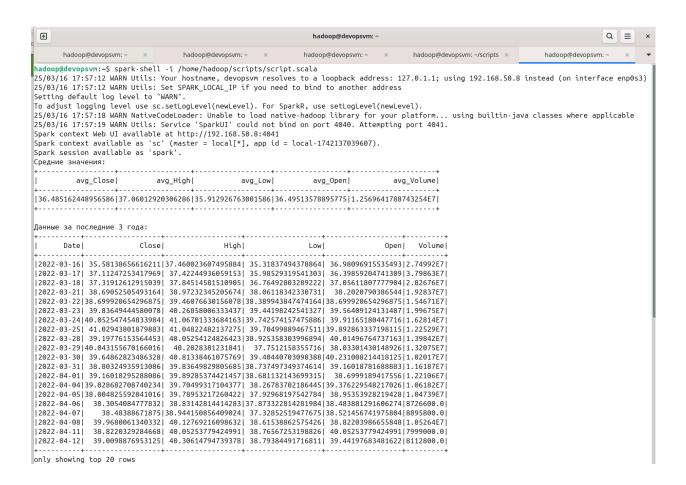
Группировка по кварталам

Сохранение результата в CSV файл

Для удобства была создана директория scripts/ и файл script.scala

Создание директории и файла script.scala с кодом

Результат выполнения:



Медианная цена закрытия: 38.074913024902344 Группировка по кварталам:	
+	rter avg_Close
Year Quar	rter avg_Close
	+
	3 16.9349362552166
2024	3 43.72580277919769
2022	2 39.226578497117565
1.	3 34.23342174291611
2024	2 47.0983515542651
2023	3 55.746014367966424
2023	2 45.60234648181546
2020	4 17.305005356669426
2023	4 52.46532997252449
2021	3 26.637318402528763
2021	2 28.453633747403583
2024	1 49.00227587340308
2020	1 25.90806208887408
2022	1 36.778632071710405
2021	1 24.2893645177122
2025	1 40.83830398168319
2020	2 15.854010763622465
2024	4 41.50260633230209
2022	4 47.20831637912326
	4 29.415187895298004
++	
only showing top 20 rows	

Выход из Spark-shell:

Шаг 6. Работа с результатами

cd /home/hadoop

Переход в директорию с результатами

Проверка результатов

После выполнения скрипта результаты будут сохранены в указанных директориях:

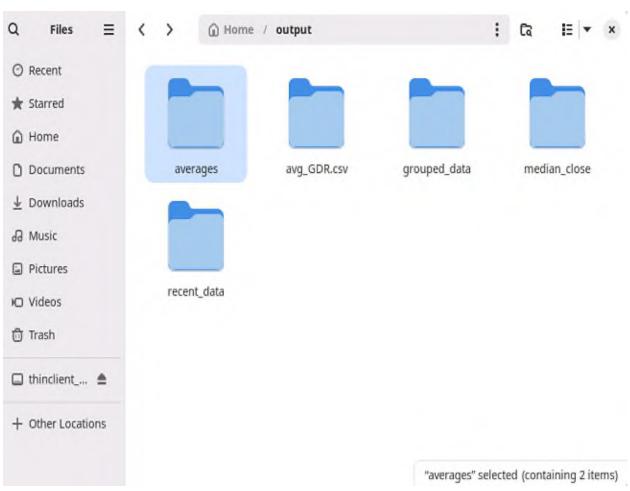
file:///home/hadoop/output/averages

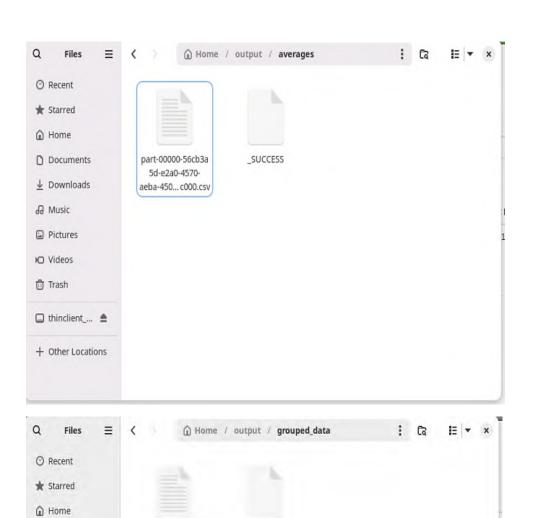
file:///home/hadoop/output/recent_data

file:///home/hadoop/output/median close

file:///home/hadoop/output/grouped_data

hadoop@devopsvm:~\$ ls /home/hadoop/output/ averages avg_GDR.csv grouped_data median_close recent_data hadoop@devopsvm:~\$





_SUCCESS

part-00000-359d14

82-6beb-4a4c-

b89a-7a3... c000.csv

Documents

☐ thinclient_... ≜

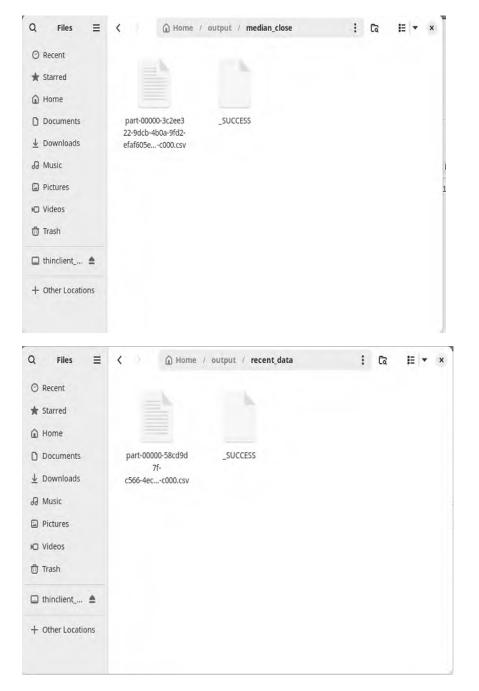
+ Other Locations

→ Music

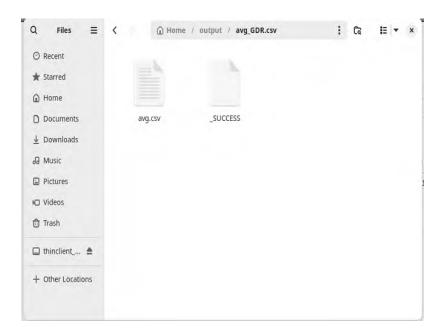
→ Pictures

→ Videos

→ Trash



Файлы из примера



Переименование файлов с результатами

Averages:

mv part-00000-*.csv avg.csv

grouped_data:

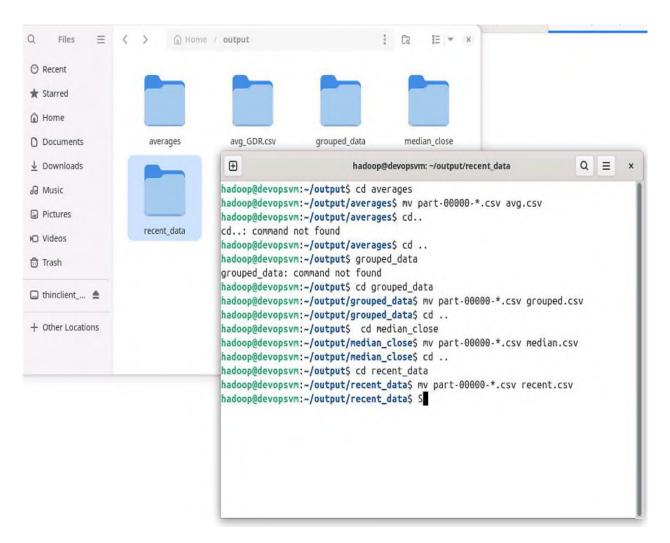
mv part-00000-*.csv grouped.csv

median:

mv part-00000-*.csv median.csv

recent:

mv part-00000-*.csv recent.csv



Загрузка результатов в HDFS

hdfs dfs -put /home/hadoop/output/averages/avg.csv /mareevga01/hadoop/input/
hdfs dfs -put /home/hadoop/output/grouped_data/grouped.csv /mareevga01/hadoop/input/
hdfs dfs -put /home/hadoop/output/median_close/median.csv /mareevga01/hadoop/input/
hdfs dfs -put /home/hadoop/output/recent_data/recent.csv /mareevga01/hadoop/input/

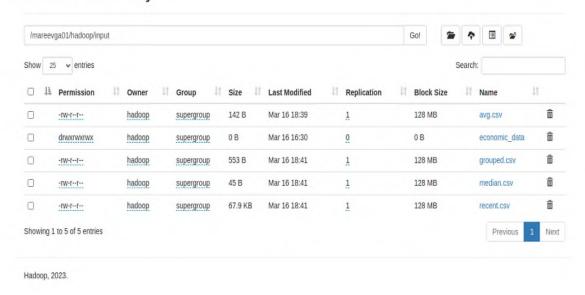
```
Q
 \oplus
                                     hadoop@devopsvm: ~/output/recent_data
                                                                                                 Ξ
hadoop@devopsvm:~/output$ grouped data
grouped_data: command not found
hadoop@devopsvm:~/output$ cd grouped_data
hadoop@devopsvm:~/output/grouped_data$ mv part-00000-*.csv grouped.csv
hadoop@devopsvm:~/output/grouped_data$ cd ...
hadoop@devopsvm:~/output$ cd median_close
hadoop@devopsvm:~/output/median close$ mv part-00000-*.csv median.csv
hadoop@devopsvm:~/output/median_close$ cd ...
hadoop@devopsvm:~/output$ cd recent_data
hadoop@devopsvm:~/output/recent_data$ mv part-00000-*.csv recent.csv
hadoop@devopsvm:~/output/recent_data$ hdfs dfs -put /home/hadoop/output/averages/avg.csv /mareevga01/ha
doop/input/
2025-03-16 18:39:50,777 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platf
orm... using builtin-java classes where applicable
hadoop@devopsvm:~/output/recent_data$ hdfs dfs -put /home/hadoop/output/grouped_data/grouped.csv /maree
vga01/hadoop/input/
2025-03-16 18:41:09,225 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platf
orm... using builtin-java classes where applicable
hadoop@devopsvm:~/output/recent_data$ hdfs dfs -put /home/hadoop/output/median_close/median.csv /mareev
ga01/hadoop/input/
2025-03-16 18:41:15,752 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platf
orm... using builtin-java classes where applicable
hadoop@devopsvm:~/output/recent_data$ hdfs dfs -put /home/hadoop/output/recent_data/recent.csv /mareevg
a01/hadoop/input/
2025-03-16 18:41:21,135 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platf
orm... using builtin-java classes where applicable
hadoop@devopsvm:~/output/recent_data$
```

Проверка загрузки

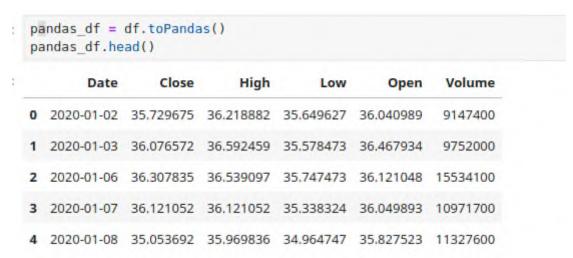
hdfs dfs -ls /mareevga01/hadoop/input/

```
hadoop@devopsvm:~$ hdfs dfs -ls /mareevga01/hadoop/input/
2025-03-16 18:42:52,232 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where app
licable
Found 5 items
                                        142 2025-03-16 18:39 /mareevga01/hadoop/input/avg.csv
-rw-r--r-- 1 hadoop supergroup
drwxrwxrwx - hadoop supergroup
                                         0 2025-03-16 16:30 /mareevga01/hadoop/input/economic_data
-rw-r--r-- 1 hadoop supergroup
                                        553 2025-03-16 18:41 /mareevga01/hadoop/input/grouped.csv
-rw-r--r-- 1 hadoop supergroup
                                         45 2025-03-16 18:41 /mareevga01/hadoop/input/median.csv
- FW - F - - F - -
            1 hadoop supergroup
                                     69534 2025-03-16 18:41 /mareevga01/hadoop/input/recent.csv
hadoop@devopsvm:~$
```

Browse Directory

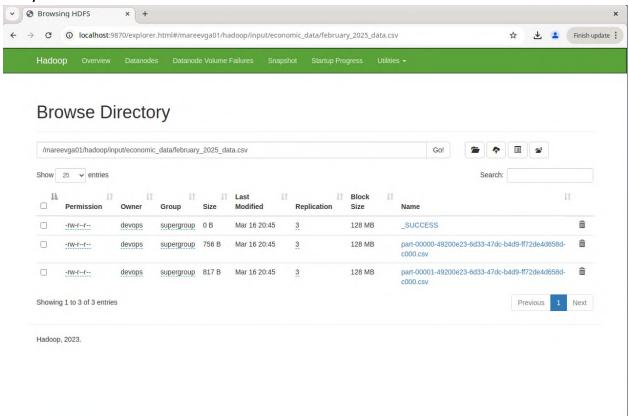


Работы в Jupyter(блокнот work_with_data_2025 приложен):



Были выгружены данные за февраль 2025 г.

Результат записи



Шаг 7. Завершение работы с Hadoop

hadoop@devopsvm:~\$ jps 20368 NodeManager 44419 Jps hadoop@devopsvm:~\$ stop-all.sh WARNING: Stopping all Apache Hadoop daemons as hadoop in 10 seconds. WARNING: Use CTRL-C to abort. Stopping namenodes on [localhost] Stopping datanodes Stopping secondary namenodes [devopsvm] 2025-03-16 20:58:26,288 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable Stopping nodemanagers Stopping resourcemanager hadoop@devopsvm:~\$ jps 20368 NodeManager 45273 Jps hadoop@devopsvm:~\$

Индивидуальное задание. Вариант 13

Поиск медианных значений и квартальная агрегация

- фильтрация данных за последние 3 года,
- расчет медианной цены закрытия,
- группировка по кварталам

Исторические данные по акциям Мечела (MLTR)

https://www.kaggle.com/datasets/svtxvt/moscow-exchange-daily-pricedata), YahooFinance (https://finance.yahoo.com/quote/MTL/history)

Так как ссылки не работали, были скачаны данные по акциям компании Schlumberger Limited (SLB) с YahooFinance за период(с "2020-01-01" по "2025-03-01")

```
import yfinance as yf

ticker = "SLB"

data = yf.download(ticker, start="2020-01-01", end="2025-03-01")

data.to_csv("slb_stock_data.csv")

print(data.head())
```

Результаты вычислений находятся в репозитории в /results:

avg.csv, grouped.csv, median.csv, recent.csv

Заключение

В результате изучения основных операций и функциональных возможностей системы удалось получить понимание принципов работы с данными и распределенными вычислениями. Были рассмотрены ключевые аспекты, такие как управление данными, выполнение операций чтения/записи, обработка больших объемов информации в распределенной среде, а также механизмы параллельных вычислений.